



Statistik und Wahrscheinlichkeitsrechnung


– Wintersemester 2020/21 –

# Kapitel 05: Spezielle Verteilungen

Prof. Dr. Adrian Ulges

Angewandte Informatik (B.Sc.) /  
Informatik - Technische Systeme (B.Sc.) /  
Wirtschaftsinformatik (B.Sc.)

Fachbereich DCSM  
Hochschule RheinMain



- ▶ **Verteilungsfunktionen  $F$**  verraten uns wie Zufallsvariablen verteilt sind. *Aber: Wie ermitteln wir  $F$ ?*
- ▶ Annahme:  $F$  gehört zu einem bestimmten **Verteilungstyp**.
- ▶ Im folgenden Kapitel werden wir uns mit einigen wichtigen Verteilungstypen auseinandersetzen, jeder mit anderen *Anwendungen, Parametern und Eigenschaften*.



## 1. Verteilungen für diskrete Zufallsvariablen

Die Bernoulli-Verteilung und Binomialverteilung

Die hypergeometrische Verteilung

Die Poisson-Verteilung

## 2. Verteilungen für stetige Zufallsvariablen

Die Uniformverteilung

Die Exponentialverteilung

Die Gauß'sche Normalverteilung



## 1. Verteilungen für diskrete Zufallsvariablen

Die Bernoulli-Verteilung und Binomialverteilung

Die hypergeometrische Verteilung

Die Poisson-Verteilung

## 2. Verteilungen für stetige Zufallsvariablen

Die Uniformverteilung

Die Exponentialverteilung

Die Gauß'sche Normalverteilung

## Definition (Bernoulli-Variable)

*Wir bezeichnen eine Zufallsvariable mit nur zwei möglichen Realisierungen (üblicher Weise 0 und 1) als **Bernoulli-Variable**.*

## Anmerkungen

- ▶ Wir bezeichnen das Ereignis  $X = 1$  als “Erfolg” und  $X = 0$  als “Misserfolg”.



## Beispiele

- ▶ Münzwurf
- ▶ Defekt von Bauteilen
- ▶ ...

# Die Bernoulli-Verteilung: Eigenschaften



## Parameter

- Die Erfolgswahrscheinlichkeit  $p := P(X = 1)$ .

## Erwartungswert und Varianz


$$E(X) = p$$

$$\text{Var}(X) = p \cdot (1 - p)$$

// Beweis: Übung

## Verteilungsfunktion

$$F(x) = \begin{cases} 0 & \text{falls } x < 0 \\ 1 - p & \text{falls } 0 \leq x < 1 \\ 1 & \text{falls } 1 \leq x \end{cases}$$




- ▶ Aus der Bernoulli-Verteilung lässt sich eine der wichtigsten Standard-Verteilungen herleiten, die **Binomial-Verteilung**.
- ▶ Wir wiederholen ein Bernoulli-Experiment  **$n$ -mal** und erhalten  $n$  **unabhängige Bernoulli-Variablen**  $X_1, \dots, X_n$ .
- ▶ Die Verteilung der Bernoulli-Variablen sei *stationär*, d.h. sie ändert sich zwischen den Wiederholungen nicht:

$$P(X_1 = 1) = P(X_2 = 1) = \dots = P(X_n = 1) = p$$

- ▶ Wir definieren eine neue Zufallsvariable  $X$ , die die **Anzahl der erfolgreichen Versuche** misst:

$$X := X_1 + X_2 + \dots + X_n$$



# Die Binomial-Verteilung: Herleitung



Wir leiten  $P(X = k)$  her:

1. Wahrscheinlichkeit einer konkreten Variation, z.B. (1,0,0,1,0):



# Die Binomial-Verteilung: Herleitung



2. **Wieviele Variationen** mit  $k$  erfolgreichen Versuchen gibt es?

## Definition (Binomial-Verteilung)

Eine diskrete Zufallsvariable  $X$  mit der Verteilung

$$P(X = k) = \begin{cases} \binom{n}{k} \cdot p^k \cdot (1 - p)^{n-k} & \text{falls } 0 \leq k \leq n \\ 0 & \text{sonst} \end{cases}$$

nennen wir *binomial-verteilt*.

# Die Binomial-Verteilung: Do-it-yourself



Berechnen Sie die Binomialverteilung für  $n = 3$  und  $p = \frac{3}{4}$ .  
Skizzieren Sie die zugehörige Verteilung als Säulendiagramm.


$k$	0	1	2	3
$\binom{n}{k}$				
$P(X = k)$				

# Die Binomial-Verteilung: Beispiel ( $n = 10, p = 0.5$ )



$$P(X = k) = \binom{10}{k} \cdot 0.5^k \cdot 0.5^{n-k}$$

$k$	0	1	2	3	4	5	6	7	8	9	10
$\binom{n}{k}$	1	10	45	120	210	252	210	120	45	10	1
$P(X=k)$	0	0.01	0.04	0.12	0.21	0.25	0.21	0.12	0.04	0.01	0




# Die Binomial-Verteilung: Beispiel ( $n = 10, p = 0.3$ )



$$P(X = k) = \binom{10}{k} \cdot 0.3^k \cdot 0.7^{n-k}$$

$k$	0	1	2	3	4	5	6	7	8	9	10
$\binom{n}{k}$	1	10	45	120	210	252	210	120	45	10	1
$P(X=k)$	0.03	0.12	0.23	0.27	0.20	0.10	0.04	0.01	0	0	0




# Die Binomial-Verteilung: Beispiel ( $n = 10, p = 0.99$ )



$$P(X = k) = \binom{10}{k} \cdot 0.99^k \cdot 0.01^{10-k}$$

$k$	0	1	2	3	4	5	6	7	8	9	10
$\binom{n}{k}$	1	10	45	120	210	252	210	120	45	10	1
$P(X=k)$	0	0	0	0	0	0	0	0	0.004	0.091	0.904



## Anwendungsbeispiel: Service Level Agreement



Die tägliche Ausfallwahrscheinlichkeit eines Servers betrage  $p = 1\%$ . Berechnen Sie die Wahrscheinlichkeit, dass der Server in einem Monat an mehr als 2 Tagen ausfällt.

Wir definieren  $X$  als die Anzahl der Ausfälle in einem Monat.

$$\begin{aligned} P(X > 2) &= 1 - P(X \leq 2) \\ &= 1 - \left( P(X = 0) + P(X = 1) + P(X = 2) \right) \\ &= 1 - \underbrace{\binom{30}{0} \cdot 0.01^0 \cdot 0.99^{30}}_{=P(X=0)} - \underbrace{\binom{30}{1} \cdot 0.01^1 \cdot 0.99^{29}}_{P(X=1)} \\ &\quad - \underbrace{\binom{30}{2} \cdot 0.01^2 \cdot 0.99^{28}}_{P(X=2)} \\ &\approx 0.33\% \end{aligned}$$



## Parameter

- ▶  $n$ : Anzahl der Wiederholungen
- ▶  $p$ : Erfolgswahrscheinlichkeit eines Versuchs.

## Notation und Eigenschaften

- ▶ Ist eine Zufallsvariable  $X$  binomialverteilt, schreiben wir auch " $X \sim B(n, p)$ ".
- ▶ Nützliche Rekursionsformel (für  $p < 1$ ):

$$P(X = k+1) = P(X=k) \cdot \left(\frac{p}{1-p}\right) \cdot \left(\frac{n-k}{k+1}\right) \quad \text{für } k = 0, \dots, n-1$$



# Die Binomial-Verteilung: Eigenschaften



Erwartungswert

Varianz

# Binomialverteilung: Beispiel mit Karten

Bild: [5]



- ▶ Wir ziehen 5 Karten aus einem Stapel von 32 Karten mit Zurücklegen.
- ▶ Was ist die Wahrscheinlichkeit, 3 Kreuz-Karten zu ziehen?
- ▶  $X :=$  Anzahl der (gezogenen) Kreuzkarten.
- ▶  $X \sim B(n=5, p=\frac{1}{4})$ .



$$\begin{aligned} P(X=3) &= \binom{5}{3} \cdot p^3 \cdot (1-p)^2 \\ &= \frac{5 \cdot 4 \cdot 3}{1 \cdot 2 \cdot 3} \cdot \left(\frac{1}{4}\right)^3 \cdot \left(\frac{3}{4}\right)^2 \\ &\approx 8.7\% \end{aligned}$$

# Binomialverteilung: Beispiel mit Karten II

Bild: [5]



- ▶ Wir wiederholen das Experiment, ziehen aber **ohne Zurücklegen**!
- ▶ Können wir immer noch die **Binomialverteilung** verwenden?
  - ▶ **Nein!** Die Wahrscheinlichkeit eine Kreuz-Karte zu ziehen ändert sich mit jedem Versuch!
  - ▶ Wir können **keine konstante Erfolgswahrscheinlichkeit  $p$**  annehmen!
- ▶ Für diese Situationen verwenden wir die **hypergeometrische Verteilung** (im Folgenden).





## 1. Verteilungen für diskrete Zufallsvariablen

Die Bernoulli-Verteilung und Binomialverteilung

Die hypergeometrische Verteilung

Die Poisson-Verteilung

## 2. Verteilungen für stetige Zufallsvariablen

Die Uniformverteilung


Die Exponentialverteilung

Die Gauß'sche Normalverteilung

# Hypergeometrische Vertlg.: Herleitung (Urnenmodell) \*


Wir leiten die gesuchte Verteilung mit Hilfe des **Urnenmodells** her.

- ▶ **Analogie: Lotto-Spielen**  
(*wieviele der "Erfolgs"-Kugeln werden gezogen?*).
- ▶  $N$  Kugeln insgesamt,  
 $K$  weiße ("Erfolg"),  
 $N - K$  schwarze ("Misserfolg").
- ▶ Wir ziehen  $n$  Kugeln **ohne Zurücklegen** und **ohne Berücksichtigung der Reihenfolge**.
- ▶ **Gesucht:**  $P(X = k)$   
(*"von den  $n$  gezogenen Kugeln sind  $k$  Stück weiß"*).



$$P(X = k) = \frac{\text{Anzahl der Kombinationen mit } k \text{ weißen und } n - k \text{ schwarzen Kugeln}}{\text{Anzahl aller möglichen Kombinationen}}$$

# Die hypergeometrische Verteilung: Herleitung




- ▶  $N$  = Anzahl aller Kugeln
  - ▶  $K$  = Anzahl aller weißen Kugeln
  - ▶  $N - K$  = Anzahl aller schwarzen Kugeln
- 
- ▶  $n$  = Anzahl der gezogenen Kugeln
  - ▶  $k$  = Anzahl der gezogenen weißen Kugeln
  - ▶  $n - k$  = Anzahl der gezogenen schwarzen Kugeln

## Nenner

- ▶ Wir betrachten zuerst den Nenner (**alle möglichen** Kombinationen): Standardformel für Ziehen *ohne Zurücklegen* und *ohne Reihenfolge*:

$$C(N; n) = \binom{N}{n}$$

# Die hypergeometrische Verteilung: Herleitung




- ▶  $N$  = Anzahl aller Kugeln
  - ▶  $K$  = Anzahl aller weißen Kugeln
  - ▶  $N - K$  = Anzahl aller schwarzen Kugeln
- 
- ▶  $n$  = Anzahl der gezogenen Kugeln
  - ▶  $k$  = Anzahl der gezogenen weißen Kugeln
  - ▶  $n - k$  = Anzahl der gezogenen schwarzen Kugeln

## Zähler

- ▶ Wieviele Kombinationen mit  $k$  (aus  $K$ ) weißen Kugeln und  $n - k$  (aus  $N - K$ ) schwarzen Kugeln gibt es?
- ▶ Für die **weißen Kugeln** gibt es  $C(K; k)$  Möglichkeiten (ohne Zurücklegen und Reihenfolge):

$$C(K; k) = \binom{K}{k}$$

# Die hypergeometrische Verteilung: Herleitung



- ▶  $N$  = Anzahl aller Kugeln
  - ▶  $K$  = Anzahl aller weißen Kugeln
  - ▶  $N - K$  = Anzahl aller schwarzen Kugeln
- 
- ▶  $n$  = Anzahl der gezogenen Kugeln
  - ▶  $k$  = Anzahl der gezogenen weißen Kugeln
  - ▶  $n - k$  = Anzahl der gezogenen schwarzen Kugeln

## Zähler

- ▶ Für die **schwarzen Kugeln** gibt es  $C(N - K; n - k)$  Möglichkeiten, d.h.

$$C(N - K; n - k) = \binom{N - K}{n - k}$$

- ▶ **Insgesamt** lautet die Anzahl der Möglichkeiten im Zähler:

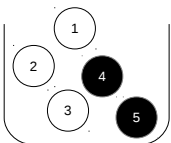
$$C(K; k) \cdot C(N - K; n - k) = \binom{K}{k} \cdot \binom{N - K}{n - k}$$



# Die hypergeometrische Verteilung: Beispiel



- ▶ Wir ziehen aus der abgebildeten Urne 3 Kugeln
- ▶ Gesuchtes Ereignis: 2 weiße Kugeln


$$P(X=2) = \frac{\begin{array}{l} \text{Wei\ss e} \\ \text{Kombina-} \\ \text{tionen} \\ \text{(2 aus 3)} \\ \binom{3}{2} \end{array} \times \begin{array}{l} \text{Schwarze} \\ \text{Kombina-} \\ \text{tionen} \\ \text{(1 aus 2)} \\ \binom{2}{1} \end{array} = \begin{array}{l} \text{Kombinationen} \\ \text{Mit 2 wei\ss en} \\ \text{und 1 schwarzen} \\ \binom{3}{2} \cdot \binom{2}{1} \end{array}}{\underbrace{\begin{array}{cccccc} \textcircled{1}\textcircled{2}\textcircled{3} & \textcircled{1}\textcircled{2}\textcircled{5} & \textcircled{1}\textcircled{3}\textcircled{5} & \textcircled{2}\textcircled{3}\textcircled{4} & \textcircled{2}\textcircled{4}\textcircled{5} \\ \textcircled{1}\textcircled{2}\textcircled{4} & \textcircled{1}\textcircled{3}\textcircled{4} & \textcircled{1}\textcircled{4}\textcircled{5} & \textcircled{2}\textcircled{3}\textcircled{5} & \textcircled{3}\textcircled{4}\textcircled{5} \end{array}}_{\begin{array}{l} \text{Alle Kombinationen} \\ \text{(3 aus 5)} \\ \binom{5}{3} \end{array}}} = \frac{6}{10}$$

## Definition (Hypergeometrische Verteilung)

Eine diskrete Zufallsvariable  $X$  mit der Verteilung

$$P(X = k) = \begin{cases} \frac{\binom{K}{k} \cdot \binom{N-K}{n-k}}{\binom{N}{n}} & \text{falls } 0 \leq k \leq n \text{ und } k \leq K \\ 0 & \text{sonst} \end{cases}$$

nennen wir *hypergeometrisch verteilt*.

## Parameter

- ▶  $N > 0$ : Gesamtzahl der Kugeln
- ▶  $K \geq 0$ : Gesamtzahl der weißen Kugeln
- ▶  $n > 0$ : Anzahl der gezogenen Kugeln

# Hypergeometrische vs. Binomialverteilung



- ▶ In der hypergeometrischen Verteilung ändert sich mit jedem Zug die Erfolgswahrscheinlichkeit  $p$ .
- ▶ Wir vergleichen die Binomialverteilung (**mit** Zurücklegen) mit der hypergeometrischen Verteilung (**ohne** Zurücklegen):

	Binomialverteilung	hypergeometrische Verteilung
1. Zug	$K/N$	$K/N$
2. Zug	$K/N$	$K/(N-1)$ oder $(K-1)/(N-1)$
3. Zug	$K/N$	$K/(N-2)$ oder $(K-1)/(N-2)$ oder $(K-2)/(N-2)$
...	...	...

- ▶ Für  $N \gg n$  sind die Unterschiede gering, d.h.


$$p_1 \approx p_2 \approx \dots \approx p_n \approx p.$$

- ▶ In diesem Fall können wir die hypergeometrische Verteilung durch die Binomialverteilung **annähern**!
- ▶ **Faustregel**: Die Approximation ist sinnvoll, wenn  $n < 0.05 \cdot N$ .

# Hypergeometrische vs. Binomialverteilung




- Die Binomialverteilung mit  $n = 10$ ,  $p = 0.2$



# Hypergeometrische vs. Binomialverteilung




- Wir reduzieren schrittweise die Kugeln in der Urne...



# Hypergeometrische vs. Binomialverteilung




►  $N = 50, K = 10$



# Hypergeometrische vs. Binomialverteilung



►  $N = 10, K = 2$



## Hypergeometrisch: Do-it-yourself Bild: [3]

Eine Lieferung aus 100 Transistoren enthält 5 defekte. In einer Kontrolle werden 4 Transistoren geprüft.



- ▶ Wie lauten  $N$ ,  $n$ , und  $K$  ?
- ▶ Berechnen Sie die Wahrscheinlichkeit, dass **genau ein** geprüfter Transistor defekt ist.
- ▶ Wie lautet die Wahrscheinlichkeit, wenn wir sie mit der Binomialverteilung **approximieren**?



# Hypergeometrisch: Do-it-yourself





## 1. Verteilungen für diskrete Zufallsvariablen

Die Bernoulli-Verteilung und Binomialverteilung

Die hypergeometrische Verteilung

Die Poisson-Verteilung

## 2. Verteilungen für stetige Zufallsvariablen

Die Uniformverteilung


Die Exponentialverteilung

Die Gauß'sche Normalverteilung



- ▶ Wir betrachten **gleichartige Ereignisse**, die **unabhängig voneinander** zu **unregelmäßigen Zeitpunkten** auftreten:
  - ▶ Kunden die ein Kaufhaus betreten
  - ▶ Jobs die in eine Warteschlange eingefügt werden
  - ▶ Autounfälle
  - ▶ Server-Ausfälle
  - ▶ Radioaktiver Zerfall von Atomen
  - ▶ ...
- ▶ Wir beobachten einen **festen Zeitraum** und möchten wissen, **wieviele** Ereignisse zu erwarten sind.

# Die Poisson-Verteilung: Formalisierung



Es sei  $X$  die Anzahl der Ereignisse über den gegebenen Zeitraum.

## Definition (Die Poisson-Verteilung)

Gegeben  $\lambda \in \mathbb{R}$ , nennen wir eine diskrete Zufallsvariable  $X$  mit

$$P(X = k) = \frac{\lambda^k}{k!} \cdot e^{-\lambda} \quad \text{für } k = 0, 1, 2, \dots$$

*Poisson-verteilt.*

# Die Poisson-Verteilung: Eigenschaften



## Anmerkungen

- ▶ Die Formel für die Poisson-Verteilung lässt sich mit Hilfe der Binomialverteilung herleiten (*hier nicht*).

## Parameter


- ▶  $\lambda > 0$  (= die **erwartete Anzahl** an Ereignissen über den Beobachtungszeitraum)

## Erwartungswert und Varianz

Ist  $X$  Poisson-verteilt (mit Parameter  $\lambda > 0$ ), gilt:

$$E(X) = \text{Var}(X) = \lambda.$$

## Die Poisson-Verteilung: Beispiel ( $\lambda = 6$ )



# Do-Poisson-Yourself



Ein Fußballfeld hat eine Fläche von 0.75 ha. Pro Quadratkilometer schlägt im Schnitt alle zwei Jahre ein Blitz ein.

Was ist die Wahrscheinlichkeit, dass binnen eines Monats der Blitz häufiger als einmal auf dem Fußballfeld einschlägt?







## 1. Verteilungen für diskrete Zufallsvariablen

Die Bernoulli-Verteilung und Binomialverteilung

Die hypergeometrische Verteilung

Die Poisson-Verteilung

## 2. Verteilungen für stetige Zufallsvariablen

Die Uniformverteilung

Die Exponentialverteilung

Die Gauß'sche Normalverteilung



## 1. Verteilungen für diskrete Zufallsvariablen

Die Bernoulli-Verteilung und Binomialverteilung

Die hypergeometrische Verteilung

Die Poisson-Verteilung

## 2. Verteilungen für stetige Zufallsvariablen

Die Uniformverteilung

Die Exponentialverteilung

Die Gauß'sche Normalverteilung

# Die Uniformverteilung



**Die 'einfachste' stetige Zufallsvariable:** Alle Werte innerhalb eines Intervalls  $[a, b]$  sind gleich wahrscheinlich.

## Definition (Uniformverteilung)

Es seien  $a, b \in \mathbb{R}$  mit  $a < b$ . Dann nennen wir eine stetige Zufallsvariable  $X$  mit der Dichtefunktion

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{falls } x \in [a, b] \\ 0 & \text{sonst} \end{cases}$$

und der Verteilungsfunktion



$$F(x) = P(X \leq x) = \begin{cases} 0 & \text{falls } x < a \\ \frac{x-a}{b-a} & \text{falls } x \in [a, b] \\ 1 & \text{falls } x > b \end{cases}$$

*uniformverteilt.*

# Die Uniformverteilung



## Illustration



## Parameter

- ▶ Intervallgrenzen  $a$ ,  $b$  (mit  $a < b$ )

## Anwendungsbeispiele

- ▶ Regentropfen die auf ein Einheitsquadrat fallen.
- ▶ Zeitpunkt von HTTP Requests an einen Server  
(*alle Sekunden in einer Minute sind gleich wahrscheinlich*).
- ▶ Die Wartezeit auf die nächste U-Bahn.

# Die Uniformverteilung: Eigenschaften



## Erwartungswert und Varianz

$$E(X) = \frac{a+b}{2}$$

$$\text{Var}(X) = \frac{1}{12}(b-a)^2$$



## 1. Verteilungen für diskrete Zufallsvariablen

Die Bernoulli-Verteilung und Binomialverteilung

Die hypergeometrische Verteilung

Die Poisson-Verteilung

## 2. Verteilungen für stetige Zufallsvariablen

Die Uniformverteilung

Die Exponentialverteilung

Die Gauß'sche Normalverteilung

## Definition (Die Exponentialverteilung)

Eine stetige Zufallsvariable  $X$  mit der Dichtefunktion

$$f(x) = \begin{cases} \lambda \cdot e^{-\lambda x} & \text{falls } x \geq 0 \\ 0 & \text{sonst} \end{cases}$$

(mit  $\lambda > 0$ ) und der zugehörigen Verteilungsfunktion

$$F(x) = P(X \leq x) = \begin{cases} 1 - e^{-\lambda x} & \text{falls } x \geq 0 \\ 0 & \text{sonst} \end{cases}$$

nennen wir *exponentialverteilt*.

## Anmerkungen

- Bei Zuverlässigkeitsuntersuchungen wird die **Funktionsdauer eines Bauteils/Systems** meist als eine exponentialverteilte Zufallsvariable modelliert (siehe unser Beispiel "Festplatte").

# Die Exponentialverteilung: Eigenschaften





## Parameter

- ▶ Einziger Parameter:  $\lambda > 0$

## Erwartungswert und Varianz

- ▶ Erwartungswert:  $E(X) = \frac{1}{\lambda}$  // haben wir schon in Kapitel 4 berechnet
- ▶ Varianz:  $Var(X) = \frac{1}{\lambda^2}$

## Dichte- und Verteilungsfunktion







# Die Exponentialverteilung: Veranschaulichung



## Annäherung durch diskrete Zufallsvariable

- ▶ Pro Zeiteinheit (z.B. jeden Tag) ein **Bernoulli-Experiment**: Bauteil fällt mit Wahrscheinlichkeit  $1 - p$  aus (Abbruch), ansonsten weiterer Betrieb.
- ▶  $X :=$  **Anzahl der Tage bis zum Ausfall**
- ▶  $P(X = k) = p^{k-1} \cdot (1 - p) \rightarrow$  fällt exponentiell mit  $k$  ab!
- ▶ Im Kontinuierlichen wird hieraus  $f(x) \propto e^{-\lambda x}$ .





## 1. Verteilungen für diskrete Zufallsvariablen

Die Bernoulli-Verteilung und Binomialverteilung

Die hypergeometrische Verteilung

Die Poisson-Verteilung

## 2. Verteilungen für stetige Zufallsvariablen

Die Uniformverteilung


Die Exponentialverteilung

Die Gauß'sche Normalverteilung

# Die Normalverteilung: Bedeutung

Die Normalverteilung ist die Verteilung

- ▶ Körpergröße, Gewicht (je Geschlecht)
- ▶ Reisezeit (auf fester Strecke)
- ▶ Größe von Schrauben
- ▶ Gewicht von Kartoffeln, Schokotafeln, ...
- ▶ Messfehler, Pixelwerte in Bildern
- ▶ IQ
- ▶ ...



Warum ist die Normalverteilung so weit verbreitet?

- ▶ Eine mathematische Begründung liefert der **Zentrale Grenzwertsatz**.
- ▶ Umgangssprachlich: "Mitteln wir viele Zufallsvariablen, so konvergiert die Verteilung des Mittelwerts gegen eine Normalverteilung."

## Definition (Gauß'sche Normalverteilung)

Eine stetige Zufallsvariable  $X$  mit der Dichtefunktion

$$\varphi(x; \mu, \sigma^2) := f(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

(wobei  $\mu \in \mathbb{R}$  und  $\sigma^2 > 0$ ) und der Verteilungsfunktion


$$\mathcal{N}(x; \mu, \sigma^2) := F(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$$

nennen wir **normalverteilt**.

## Anmerkungen

- ▶  $\mu$  entspricht dem Erwartungswert:  $E(X) = \mu$
- ▶  $\sigma^2$  entspricht der Varianz:  $\text{Var}(X) = \sigma^2$
- ▶ Für  $\mu = 0$  und  $\sigma^2 = 1$  nennen wir  $X$  standardnormalverteilt.  
Statt  $\mathcal{N}(x; 0, 1)$  schreiben wir einfach nur  $\mathcal{N}(x)$ .

# Die Gauß'sche Normalverteilung: Eigenschaften



- ▶ Die Gestalt der Dichtefunktion  $\varphi$  erinnert an eine Glocke. Deshalb sprechen wir auch von der *Gauß'schen Glockenkurve* oder **Gauß-Glocke** (engl. "bell curve").
- ▶  $\varphi$  ist **symmetrisch** zu  $x = \mu$ .
- ▶  $\varphi$  besitzt das einzige lokale **Maximum** bei  $x = \mu$ .
- ▶ Die einzigen beiden **Wendepunkte** von  $\varphi$  liegen bei  $\mu \pm \sigma$ .
- ▶ Das **Beispiel** zeigt:  $\varphi(x; 2, 3^2)$  und  $\varphi(x; 0, 1^2)$  (die Standardnormalverteilung).

# Die Gauß'sche Normalverteilung: Berechnung



**Wie berechnen wir die Wahrscheinlichkeit  $P(a \leq X \leq b)$**   
(z.B. dass die Körpergröße zwischen 170 und 190 cm liegt)?

Unser bekannter Ansatz

$$\begin{aligned} P(a \leq X \leq b) &= F(b) - F(a) \\ &= \int_a^b \underbrace{\frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{(t-\mu)^2}{2\sigma^2}}}_{\varphi(t;\mu,\sigma^2)} dt \end{aligned}$$

**Schlüsselproblem: Nicht-Integrierbarkeit der Normalverteilung**

- ▶ Wir können für die Stammfunktion von  $\varphi$   
keine geschlossene Form bestimmen!
- ▶ **Übung:** Versuchen Sie die Stammfunktion  
von  $e^{-t^2}$  zu finden.


# Die Gauß'sche Normalverteilung: Berechnung



- ▶ Wir approximieren die gesuchte Wahrscheinlichkeit  $P(a \leq X \leq b)$  mittels **numerischer Integration**.
- ▶ **Techniken**: Rechteckregel, Trapezregel, Simpson-Regel, Monte-Carlo-Integration, ...
- ▶ Die resultierenden Werte speichern wir in **Tabellen** und lesen sie bei Bedarf ab.

## “Faustregel” Bild: [9]

- ▶ Es gibt Faustregeln für die Bereiche  $[\mu \pm k \cdot \sigma]$
- ▶ *Beispiel*:  $P(\mu - \sigma \leq X \leq \mu + \sigma) \approx 68.27\%$



# Die Gauß'sche Normalverteilung: Berechnung Bild: [7]



Genereller Ansatz: Standardisierung + Wertetabelle

Wir **standardisieren** die Zufallsvariable  $X$   
und lesen  $\mathcal{N}$  aus einer Tabelle ab. *Wird im Folgenden erklärt.*

$u$	0	1	2	3	4	5	6	7	8	9
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5639	0,5675	0,5714	0,5754
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7258	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7518	0,7549
0,7	0,7580	0,7612	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7996	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8398
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545



## Satz (Standardisierung normalverteilter Variablen)

Es sei  $X \sim \mathcal{N}(x; \mu, \sigma^2)$  eine normalverteilte Zufallsvariable mit Erwartungswert  $\mu$  und Varianz  $\sigma^2$ . Dann ist

$$Y := \frac{X - \mu}{\sigma}$$

eine **standard**normalverteilte Zufallsvariable.

## Anmerkung

- ▶ Mit Hilfe dieses Satzes verwandeln wir  $X$  in eine **standard**normalverteilte Variable  $Y$ . Wir bezeichnen diesen Prozess als **Standardisierung**.
- ▶ Durch die Standardisierung brauchen wir keine Tabelle für jedes  $\mu$  und  $\sigma$ : Eine einzige Tabelle für die **Standard**normalverteilung reicht!

# Standardisierung normalverteilter Variablen



Beweis

# Standardisierung normalverteilter Variablen



Wie wir  $P(a \leq X \leq b)$  berechnen

1. Standardisiere  $X$ , d.h. definiere  $Y \sim \mathcal{N}(0, 1)$  als

$$Y := (X - \mu)/\sigma$$

2. Berechne die Grenzen  $a', b'$ :

$$a' := (a - \mu)/\sigma$$

$$b' := (b - \mu)/\sigma$$

3. Es gilt:  $P(a \leq X \leq b) = P(a' \leq Y \leq b') = \mathcal{N}(b') - \mathcal{N}(a')$
4. Lese  $\mathcal{N}(a')$  und  $\mathcal{N}(b')$  aus Tabellen der Standardnormalverteilung ab (*interpoliere ggfs. zwischen den diskreten Werten der Tabelle, um die Genauigkeit zu erhöhen*).



- ▶ Der IQ lässt sich als in der Gesamtbevölkerung normalverteilte Zufallsvariable  $X$  mit  $\mu = 100$  und  $\sigma = 15$  beschreiben.
- ▶ Bob hat einen IQ von 120, Charly einen IQ von 90.
- ▶ Wieviele Prozent der Bevölkerung besitzen einen IQ zwischen dem Charlys und Bobs?
- ▶ Wieviele Prozent besitzen einen höheren IQ als Bob?




$u$	0	1	2	3	4	5	6	7	8	9
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5639	0,5675	0,5714	0,5754
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7258	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7518	0,7549
0,7	0,7580	0,7612	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7996	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8398
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545

Beispiel: IQ



## Symmetrie

- ▶ Warum fehlen in der Tabelle **negative Werte** ?
- ▶ Aufgrund der Symmetrie von  $\varphi$  gilt:  $\mathcal{N}(-x) = 1 - \mathcal{N}(x)$ .  
Wir können negative Werte also auch aus der Tabelle gewinnen.



## Quantile

- ▶ Oft ist eine **Wahrscheinlichkeit  $\alpha$**  gegeben, und wir suchen das  **$\alpha$ -Quantil**, d.h. jenes  $x_\alpha$  für das gilt  $P(X \leq x_\alpha) = \alpha$
- ▶ Diese Werte sind ebenfalls in vorgefertigten Tabellen verfügbar.

$\alpha$	$x_\alpha$
0.001	-3.090
0.005	-2.576
0.01	-2.326
0.025	-1.960
0.05	-1.645
0.1	-1.282
0.9	1.282
0.95	1.645
0.975	1.960
0.99	2.326
0.995	2.576
0.999	3.090



# Standardnormalverteilung: Do-it-yourself



*Bei der Massenproduktion von Gewindeschrauben ist der gemessene Durchmesser (in mm) eine Zufallsvariable*

$$X \sim \mathcal{N}(x; \mu = 10, \sigma^2 = 4).$$

- ▶ Eine Abweichung vom Sollwert (= 10 mm) von 3 mm kann gerade noch toleriert werden. Welcher Ausschuss-Anteil ist zu erwarten?
- ▶ Wie müsste die Standardabweichung lauten, damit der Ausschuss-Anteil nur 2% beträgt?

# Standardnormalverteilung: Do-it-yourself



# Standardnormalverteilung: Do-it-yourself



## Praxisbeispiel: “Six Sigma” \*\*\*



- ▶ Produktionsprozesse werden immer weiter perfektioniert – hierbei spielen statistische Verfahren eine große Rolle.
- ▶ Ziel ist in der Regel die Produktion “möglichst gleicher” Teile, d.h. die **Standardabweichung** der Artikel einer Produktionslinie soll möglichst gering sein.
- ▶ Unter dem Namen “**Six Sigma**” wurde eine Methode des Qualitätsmanagements bekannt, um die Standardabweichung  $\sigma$  soweit zu senken, dass nur noch Werte außerhalb eines **Toleranzbereiches von 6 Standardabweichungen** ( $6\sigma$ , daher der Name) als Ausschuss betrachtet werden müssen.
- ▶ Da in der Praxis die Lage des Mittelwerts driften kann, wird das Qualitätslimit in der Praxis von  $6\sigma$  auf  $4.5\sigma$  gesenkt.
- ▶ Wir suchen also:  $P(|X - \mu| > 4.5\sigma)$

$$P(|X - \mu| > 4.5\sigma) = 1 - \left( \mathcal{N}(4.5) - \mathcal{N}(-4.5) \right) = 0.0000068$$

- ▶ Das bedeutet: Ziel sind höchstens **6.8 Defekte** unter **1 Million** produzierter Artikel.



- [1] Dylan Meconis: Parent Line.  
<https://flic.kr/p/5R2khv> (changed to black and white, CC license, retrieved: Dec 2016).
- [2] Fairphone: Fairphone quality control check.  
<https://flic.kr/p/iQLoHE> (retrieved: Dec 2016).
- [3] Martin Bircher: Transistors.  
<https://flic.kr/p/94gcGL> (retrieved: Dec 2016).
- [4] Nationwide Poll Results for 2008 Presidential Election.  
[https://commons.wikimedia.org/wiki/File:Nationwide\\_Poll\\_Results\\_for\\_2008\\_Presidential\\_Election.svg](https://commons.wikimedia.org/wiki/File:Nationwide_Poll_Results_for_2008_Presidential_Election.svg) (retrieved: Oct 2016).
- [5] Olli Henze: 4 Asse.  
<http://www.ohenze.de/> (retrieved: Nov 2016).
- [6] Sean Fallon: Statistical Distribution Plushies: Hug The Math.  
<http://nerdapproved.com/approved-products/statistical-distribution-plushies-hug-the-math/> (retrieved: Dec 2016).
- [7] L. Papula.  
Mathematik für Ingenieure und Naturwissenschaftler, volume 3.  
Friedrich Vieweg & Sohn Verlagsgesellschaft mbH, Braunschweig/Wiesbaden, 4 edition, 2001.
- [8] unknown.  
Jakob Bernoulli.  
[https://commons.wikimedia.org/wiki/File:Jakob\\_Bernoulli.jpeg](https://commons.wikimedia.org/wiki/File:Jakob_Bernoulli.jpeg) (retrieved: Dec 2016).
- [9] Eggert Winter, editor.  
Gabler Wirtschaftslexikon.  
Gabler, 18. edition, 2013.